ANÁLISIS EXPLORATORIO DE DATOS

Reporte de Hallazgos y Preparación de Datos

Smart Meters London · UK Power Networks · 2011–2014

Focalización de Programas de Eficiencia Energética mediante Machine Learning

Fecha	2025
Dataset	Smart Meters in London (Kaggle / UK Power Networks)
Fuente	https://www.kaggle.com/datasets/jeanmidev/smart-meters-in-london
Etapa	Preparación de Datos y Análisis Exploratorio (EDA)

1. Contexto y Objetivo del Análisis

Este reporte documenta los hallazgos del análisis exploratorio de datos (EDA) realizado sobre el dataset Smart Meters in London, como primera etapa del proyecto de Machine Learning orientado a la toma de decisiones energéticas. El objetivo de negocio que guía todo el análisis es:

> **¿A cuáles de mis clientes debo contactar primero, y con qué oferta?**
> Una distribuidora de energía requiere identificar hogares con consumo anómalo, predecir demanda futura y segmentar su base de clientes para diseñar intervenciones de eficiencia energética focalizadas.

El análisis integra cuatro fuentes de datos complementarias:

Archivo	Contenido	Rol en el Proyecto
daily_dataset.csv	Consumo diario por hogar (kWh)	Base principal de análisis
informations_households.csv	Tarifa (ToU/Std) y grupo Acorn	Variables de segmentación
weather_daily_darksky.csv	Clima diario en Londres	Variables externas explicativas
hhblock_dataset (muestra)	Consumo cada 30 min	Análisis de perfil intradiario

2. Resumen del Dataset

2.1 Volumen y Cobertura

El dataset consolidado, tras los filtros de calidad aplicados, presenta las siguientes características:

5,384	822	3,426,461	33
Hogares analizados	**Días con datos**	**Registros totales**	**Variables construidas**
Nov 2011 – Feb 2014	Período de 26 meses con datos completos		

2.2 Calidad de Datos

El análisis de valores faltantes reveló una calidad general alta en todas las fuentes:

Fuente	NaN detectados	Porcentaje	Tratamiento
daily_dataset.csv	11,361 (energy_std)	0.32%	Aceptable — registros con pocos periodos
informations_households.csv	0	0.00%	Sin acción requerida
weather_daily_darksky.csv	2 (cloudCover, uvIndex)	0.11%	Sin impacto práctico
Temperatura tras join	10,544	0.30%	Días fuera del rango climático

Decisión de filtrado: se descartaron 182 hogares (3.3% del total) con menos de 365 días de datos, al no contar con historia suficiente para construir lag features confiables. Los 5,384 hogares restantes tienen en promedio 631 días de cobertura (mediana: 651 días), lo que garantiza solidez estadística en los modelos.

3. Composición de la Base de Clientes

3.1 Distribución por Tipo de Tarifa

El 79.7% de los hogares opera bajo tarifa estándar (Std), mientras el 20.3% restante participa en el programa de tarifa dinámica por tiempo de uso (ToU). Este balance es relevante porque la variable tarifa resultó estadísticamente significativa en el comportamiento de consumo.

Tipo de Tarifa	N° Hogares	Participación

Std (Estándar)	4,289	**79.7%**
ToU (Tiempo de Uso)	1,095	**20.3%**

Test estadístico: la prueba Mann-Whitney arrojó $p < 0.0001$, confirmando que la diferencia de consumo entre tarifas no es atribuible al azar. Los hogares con tarifa ToU exhiben patrones de consumo distintos, posiblemente por mayor conciencia del precio o adaptación horaria.

3.2 Distribución por Grupo Socioeconómico (ACORN)

La clasificación ACORN segmenta los hogares en tres grandes grupos con perfiles socioeconómicos diferenciados:

Grupo ACORN	N° Hogares	%	Perfil
Affluent	2,114	**39.3%**	Hogares con mayores ingresos y propiedades
Adversity	1,754	**32.6%**	Hogares en dificultad económica
Comfortable	1,469	**27.3%**	Hogares con ingresos medios
ACORN-U / -	47	**0.9%**	Sin clasificación

4. Análisis del Consumo Energético

4.1 Estadísticas Descriptivas

El consumo diario por hogar presenta una distribución asimétrica a la derecha, con una larga cola superior que refleja la existencia de hogares con consumo extraordinariamente alto:

Estadístico	Valor	Interpretación
Media	**10.13 kWh/día**	Consumo promedio por hogar
Mediana	**7.83 kWh/día**	50% de hogares consumen menos
Desv. Estándar	**9.10 kWh/día**	Alta variabilidad entre hogares
Percentil 25	**4.69 kWh/día**	Hogares de consumo bajo
Percentil 75	**12.58 kWh/día**	Hogares de consumo medio-alto
Máximo	**332.56 kWh/día**	Valor extremo — candidato a anomalía

Nota: la brecha media-mediana (10.13 vs 7.83 kWh/día) confirma que la distribución no es simétrica y que existe una minoría de hogares con consumo muy elevado que jala el promedio hacia arriba.

4.2 Heterogeneidad entre Hogares

El hallazgo más relevante para la estrategia de segmentación es la alta dispersión del consumo entre hogares:

> **Consumo promedio mínimo: ~0 kWh/día | Consumo promedio máximo: 101.37 kWh/día**
> El hogar más consumidor usa más de 100 veces más energía que el más eficiente.
> Esta heterogeneidad no es ruido — es información. Justifica técnica y comercialmente la aplicación de clustering para crear grupos diferenciados.

5. Patrones Temporales de Consumo

5.1 Estacionalidad

El consumo muestra una marcada estacionalidad anual. Los meses de invierno (diciembre–febrero) concentran los picos de demanda, mientras que el verano registra los niveles más bajos:

- Invierno consume aproximadamente 2 veces más que verano, patrón consistente con el uso de calefacción eléctrica en el contexto del Reino Unido.
- El indicador HDD (Heating Degree Days) —diferencia entre 15.5°C y la temperatura media diaria— explica la mayor parte de esta variación estacional.
- La correlación consumo vs. temperatura media es −0.1718 (a mayor temperatura, menor consumo), y consumo vs. HDD es +0.1740, confirmando la relación inversa esperada.

5.2 Patrón Semanal

El análisis por día de la semana revela diferencias consistentes entre días hábiles y fin de semana:

- Los fines de semana presentan mayor consumo en horas diurnas (presencia en el hogar).
- Los días de semana concentran el pico en la franja 17:00–19:00 h (regreso al hogar).
- La variable is_weekend fue incluida en los tres grupos de features para los modelos posteriores.

5.3 Perfil Intradiario (cada 30 minutos)

A partir de la muestra de 500 hogares del hhblock_dataset (10 bloques, 14.6 millones de registros transformados), se identificó el perfil de consumo intradiario:

- Consumo mínimo: 02:00–05:00 h (madrugada).
- Rampa de ascenso: 06:00–09:00 h (rutina matutina).
- Pico principal: 16:00–19:00 h, coincidente con el regreso al hogar y uso simultáneo de electrodomésticos.
- El patrón difiere entre días de semana y fin de semana: en estos últimos el pico matutino es más pronunciado y el diurno más sostenido.

6. Análisis de Anomalías Preliminar

Se realizó una detección estadística preliminar de anomalías mediante Z-score por hogar (umbral |Z| > 3). Este análisis sirvió como línea base para justificar la aplicación posterior de Isolation Forest:

Indicador	Resultado
Registros anómalos detectados (Z > 3)	**34,127 (1.00% del total)**
Hogares con ≥ 5 días anómalos	**3,182 (59.1% de los hogares)**
Consumo máximo registrado	332.56 kWh/día (caso extremo)

Implicación para el negocio:
El 59.1% de los hogares tiene al menos 5 días con consumo estadísticamente inusual. Esto no significa necesariamente desperdicio — puede reflejar eventos como vacaciones, averías o uso especial de equipos. El modelo de Isolation Forest en la siguiente etapa diferenciará entre anomalías de alta y baja magnitud para priorizar las intervenciones.

7. Correlaciones e Importancia de Variables

7.1 Correlaciones con el Consumo Diario

El análisis de correlación reveló que las variables de mayor poder predictivo son las propias mediciones pasadas del hogar (autocorrelación), seguidas por indicadores de dispersión del consumo:

Variable	Correlación	Tipo	Interpretación
rolling_7d	**0.9150**	Rolling mean (lag)	Muy alta — tendencia reciente del hogar

lag_1d	**0.9083**	Lag temporal	Muy alta — autocorrelación diaria
rolling_30d	**0.8904**	Rolling mean (lag)	Alta — tendencia mensual del hogar
lag_7d	**0.8545**	Lag temporal	Alta — mismo día semana anterior
energy_std	**0.7775**	Estadística diaria	Alta — variabilidad predice magnitud
energy_max	**0.7639**	Estadística diaria	Alta — pico predice consumo total
energy_min	**0.7107**	Estadística diaria	Alta — base de consumo
HDD	0.1740	Clima	Moderada — efecto calefacción
temp_mean	-0.1718	Clima	Moderada negativa — frío aumenta consumo
humidity	0.0799	Clima	Débil

7.2 Importancia de Variables (Random Forest)

Se entrenó un Random Forest con 100,000 registros de muestra para cuantificar la importancia relativa de cada variable como predictor del consumo diario:

Variable	Importancia	Interpretación
rolling_7d	**73.42%**	Domina el modelo — promedio 7d captura tendencia del hogar
lag_1d	**13.54%**	Segundo factor — consumo ayer predice consumo hoy
energy_std	**6.14%**	Variabilidad diaria tiene poder predictivo adicional
energy_min	3.25%	Consumo base del hogar
energy_max	2.35%	Consumo pico del hogar
rolling_30d	0.37%	Tendencia mensual (redundante con rolling_7d)
rolling_std_7d	0.29%	Volatilidad reciente
lag_7d	0.24%	Mismo día semana anterior
Variables climáticas	< 0.1% c/u	Contribución marginal individual, no despreciable en conjunto
Variables categoricas	< 0.1% c/u	tarifa_enc, acorn_enc: efecto real pero mediado por comportamiento

> **Hallazgo clave: rolling_7d sola explica el 73.42% de la varianza.**
> Esto es esperable en series temporales con fuerte autocorrelación. Sin embargo, no significa que el resto de variables sea irrelevante: las variables climáticas y categóricas aportan en los casos donde el comportamiento se desvía de la tendencia histórica — precisamente los casos de interés para detección de anomalías.

8. Variables Seleccionadas por Modelo

Con base en el análisis de correlaciones, importancia de variables y la naturaleza de cada objetivo de negocio, se definieron tres grupos de features diferenciados:

8.1 Modelo de Regresión — Predicción de Consumo Diario

Objetivo: predecir el consumo kWh/día por hogar para los próximos días.

- Lags: lag_1d, lag_7d
- Rolling means: rolling_7d, rolling_30d, rolling_std_7d
- Temporales: month, day_of_week, is_weekend, season_enc
- Climáticas: temp_mean, HDD, humidity, cloudCover
- Categóricas: tarifa_enc, acorn_enc

8.2 Modelo de Anomalías — Isolation Forest

Objetivo: identificar días con consumo inusual respecto al perfil histórico del hogar.

- Consumo: energy_sum, energy_vs_mean (consumo normalizado por promedio histórico del hogar)
- Rolling: rolling_7d, rolling_std_7d
- Climáticas: temp_mean, HDD
- Contexto: month, is_weekend

8.3 Modelo de Clustering — Segmentación de Hogares

Objetivo: agrupar hogares por perfil de consumo para personalizar intervenciones. Opera a nivel de hogar (un vector por hogar).

- consumo_medio, consumo_std, consumo_max
- consumo_invierno, consumo_verano (estacionalidad)
- consumo_finde, consumo_semana (patrón semanal)
- ratio_invierno_verano (sensibilidad térmica del hogar)

9. Justificación de los Tres Modelos

Modelo	Evidencia del EDA	Decisión de negocio	Algoritmos a comparar
Regresión	Autocorrelación muy alta (rolling_7d r=0.91). El consumo pasado predice el futuro.	¿Cuánta capacidad de red necesito la próxima semana?	Random Forest vs XGBoost
Anomalías	34,127 registros anómalos (1%). 3,182 hogares con ≥5 días inusuales.	¿A qué hogares ofrecer auditoría energética gratuita?	Isolation Forest vs Z-Score estadístico
Clustering	Rango de consumo: 0 – 101.37 kWh/día. Diferencia confirmada por tarifa y Acorn.	¿Qué oferta o tarifa diseñar para cada segmento?	K-Means + PCA para visualización

10. Limitaciones del Análisis

- Cobertura geográfica: todos los hogares pertenecen a Londres (UK). Los patrones climáticos y de comportamiento pueden diferir en otros contextos geográficos.
- Período temporal: los datos cubren 2011–2014. Cambios en tecnología doméstica (vehículos eléctricos, paneles solares) hacen que el dataset no refleje el parque actual de hogares.
- Perfil intradiario: el análisis de 30 minutos se realizó sobre una muestra de 500 hogares (10 de 112 bloques) por memoria. Los patrones son representativos pero no exhaustivos.
- Variable de consumo: el dataset reporta consumo total del hogar sin discriminar por tipo de uso (calefacción, iluminación,). Esto limita el diagnóstico de la causa raíz de anomalías.
- Causalidad vs. correlación: las altas correlaciones de los lags con el consumo son descriptivas, no causales. El modelo de regresión predice bien en condiciones normales pero puede fallar ante cambios estructurales en el comportamiento del hogar.

11. Próximos Pasos

#	Etapa	Entregable	Archivo
1	**Modelado — Regresión (Random Forest y XGBoost)**	Modelos entrenados + comparativa de métricas	02_modelo_regresion.ipynb
2	**Modelado — Detección de Anomalías (Isolation Forest)**	Score de anomalía por hogar-día	03_modelo_anomalias.ipynb
3	**Modelado — Clustering (K-Means + PCA)**	Segmentos de hogares con descripción	04_modelo_clustering.ipynb
4	**Dashboard Streamlit**	App funcional para usuario no técnico	dashboard/app.py
5	**Reporte ejecutivo final**	Reporte de consultoría completo	reports/reporte_final.pdf